- **تمرینات تئوری**

۱. **سوالات چهارگزینه ای (بیان شرح علت انتخاب گزینه لازم است، هر سوال ۴ نمره می باشد) :**

۱.۱. نتایج عملکردی یک مدل تشخیص ایمیل های spam و not spam در قالب Confusion Matrix به شرح زیر می باشد. مقدار f1-score این مدل کدام است؟

Confusion Matrix		Predicted Value	
		Positive	Negative
Actual Values	Positive	50	10
	Negative	5	35

a) 0.6 b) 0.7 c) 0.8 d) 0.9

۲.۱. کدام یک از گزینه های زیر به یک روش مرسوم در Minimum Edit Distance اشاره می کند؟

a) Parallel Programming

b) Dynamic Programming

c) Pair programming

d) هیچکدام

۳.۱. کدام یک از گزینه های زیر حاصل عبارت منظم /^[A-Z][a-zA-Z]{3,5}[nt][gr]$/ نمی باشد؟

a)Drawing b)Playing c)Running d)Runner

۴.۱. کدام یک از گزینه های زیر حاصل عبارت منظم زیر می باشد؟

/$[a-zA-Z._%+-]+@[a-z]{2,}\.[a-zA-Z0-9.-]+\.ir^/

a) cemanager@ce.guilan.ac.ir

b) cemanager403@ce.guilan.ac.ir

c) elmanager@e.guilan9.ac.ir

d) chemical_group@ch.guilan.ac.com

۱.۵. Stemming در textmining به کدام یک از گزینه های زیر اشاره دارد؟

a) تبدیل جمله به کلمه

b) تبدیل پاراگراف به جمله

c) تبدیل کلمه به ریشه

d) تبدیل کلمه به اجزای کلمه

۲. سه دسته از Task های حوزه پردازش زبان طبیعی را بیان کرده و برای هر یک دو مثال ارائه نمائید. (۳ نمره)

۳. عبارت های منظم زیر را توضیح دهید و یک مثال برای رشته های قابل قبول در هر کدام از عبارت های منظم را ارائه دهید. (۵ نمره)

a) (\d{2})/(\d{2})/(\d{2}|\d{4})

b) /^ [aeiou] [a-z]* [^aeiou] $/

c) / (\w)(?:(?R)|\w?)\1 /

۴. چه عبارت منظمی را پیشنهاد میکنید که به طور خاص کلمه مستقل Learning را شناسایی کند و در عین حال اطمینان حاصل کنید که هیچ کلمه دیگری مانند MachineLearning و DeepLearning و LearningRate و ... را شامل نشود. (۴ نمره)

۵. Lemma و Wordform را برای کلمات Swimming و Swimmer مورد بررسی قرار دهید. (۵ نمره)

۶. حداقل تعداد عملیات های لازم جهت تبدیل رشته aggregation به gathering را با رسم جدول Edit Distance محاسبه کنید (هزینه Substitution را برابر با ۲ و سایر Operation ها را برابر با ۱ فرض شود). (۷ نمره)

۷. چرا معیارهای Precision و Recall برای ارزیابی میزان موفقیت عملکرد مدل های Classifier کافی نیستند؟ در یک نمونه Classifier ، بررسی کنید که این معیارها چه مشکلاتی دارند؟ معیار بهتر برای ارزیابی چیست؟ (۴ نمره)

۸. فرض کنید به عنوان یک تحلیلگر داده در مجموعه دیجی کالا شـروع به فعالیت کرده اید. نیروی قبلی یک دسـته بند (Classifier) ایجاد کرده بود که بر اسـاس نظرات محصـولات ، احسـاس کاربران نسـبت به هر محصـول را تشـخیص میداد. این دسته بند از یک مجموعه داده ۱۰۰۰ نمونه ای استفاده کرده که شامل ۷۵۰ مورد مثبت و ۲۵۰ مورد منفی اسـت. این دسـته بند ۶۵۰ نظر مثبت را به درسـتی و ۱۰۰ نظر مثبت را به اشـتباه طبقه بندی کرده اسـت . همچنین ۱۸۰ نظر منفی را به درسـتی و ۷۰ نظر منفی را به اشـتباه طبقه بندی اسـتفاده اسـت. مدیر بخش تحلیل داده از شـما خواسته است که معیارهای Precision و Recall و F1-Score را برای این دسته بند گزارش کنید. (۷ نمره)

۹. با توجه به جدول زیر مشخص کنید سند شماره ۶ مربوط به چه کلاسی است؟ (استفاده از روش Naive Bayes) (۸ نمره)

$$\hat{P}(w \mid c) = \frac{count(w,c)+1}{count(c)+|V|}$$

Documents	Words	Class
1	Technology, Stemming, Lemmatization	T
2	Recognition, Learning, Data	T
3	Neural, Network, Lemmatization	T
4	Router, Switch, Network	N
5	Network, Bandwidth, Router	N
6	Recognition, Learning, Router	?

۱۰. فرض کنید یک مدل زبانی احتمالات n-gram را به یک مجموعه تسـت ۵ کلمه‌ای به صـورت زیر اختصـاص می‌دهد. احتمال کل مجموعه تست را محاسبه کنید. و با توجه به طول مجموعه تست، Perplexity این مدل را حساب کنید. (۷ نمره)

$$\frac{1}{2}\text{ و }\frac{1}{3}\text{ و }\frac{1}{4}\text{ و }\frac{1}{5}\text{ و }\frac{1}{6}$$

- **تمرینات عملی**

۱. یک مرحله مهم در پردازش زبان طبیعی، **پیش‌پردازش داده** اسـت. Task های زیر را با اسـتفاده از کتابخانه parsivar انجام دهید. (۸ نمره)

الف) با استفاده از توابع موجود در این کتابخانه ، متن زیر را Normalize کنید. سپس بررسی کنید که چه تغییراتی در متن ایجاد شده است.

پردازش زبان‌های طبیعی یکی از شـاخه‌های هوش مصـنوعی اسـت که به تعامل بین کامپیوتر و زبان انسـانی می‌پردازداز کاربردهای مهم آن می‌توان به ترجمه ماشـینی،چت‌بات‌ها و تحلیل احسـاسـات اشـاره کرد.یکی از نخسـتین تلاش‌ها در این زمینه‌به سـال هزار و نهصـد و پنجاه و هفت‌بازمی‌گردد که مدل‌های اولیه ترجمه خودکار توسـعه یافتند..امروزه در سال ۱۴۰۳ مدل‌های جدید مبتنی بر یادگیری عمیق دقت بالایی در تحلیل زبان دارند.

ب) پس از نرمال سازی ، با استفاده از تابع tokenize_sentences ، متن را به جملات مجزا تبدیل کنید.
ج) با استفاده از توابع موجود ، کلمات موجود در متن را tokenize کنید و نتایج را نمایش دهید.
د) با استفاده از قابلیت Stemming این کتابخانه ، ریشه کلمات زیر را پیدا کنید.

درختان ، اژدها ، رفتارها ، برقص ، بنواز ، کفار ، برآشفتن

۲. TensorFlow یک کتابخانه متن‌باز یادگیری عمیق از گوگل است که برای ساخت و آموزش مدل‌های هوش مصنوعی، به‌ویژه شبکه‌های عصبی، استفاده می‌شود. این کتابخانه از پردازش موازی روی CPU و GPU پشتیبانی می‌کند و در پروژه‌های یادگیری عمیق کاربرد گسترده‌ای دارد. یکی از امکانات TensorFlow مجموعه ای از دیتاست های مختلف است که در این تمرین میخواهیم بر روی یکی از این دیتاست ها ، عمل vectorization را انجام دهیم. در ابتدا سعی کنید دیتاست ag_news_subset بر روی محیط اجرای خود load کنید. این دیتاست شامل دو بخش train و test می باشد که جزئیات آن در لینک این دیتاست در دسترس است. این دیتاست شامل نمونه هایی از کلاس های world ، sport ، business و sci/tech می باشد. در ادامه خواسته های تمرین را بیان می کنیم.
در بخش اول ، سعی کنید چند نمونه از داده های موجود در دیتاست را به همراه کلاس های آن ها نمایش دهید.
در بخش دوم ، سعی کنید که کلمات موجود در دیتاست را vectorize کنید. برای این کار میتوانید از تابع keras.layers.TextVectorization استفاده کنید. توجه کنید که کلمات موجود در vocabulary باید حدود ۵۰۰۰ کلمه باشند. در نهایت کلمات موجود در vocabulary و تعداد آنها را نمایش دهید. (۱۰ نمره)

۳. با استفاده از کتابخانه‌ی NLTK در زبان Python، یک تحلیلگر احساسات بسازید. این برنامه باید متن ورودی کاربر را دریافت کرده و با استفاده از یک مدل ساده‌ی *Naive Bayes Classifier* ، احساسات آن را تحلیل کند. دیتاست پیشنهادی مجموعه داده‌ی twitter-airline-sentiment از این لینک است که شامل نظرات کاربران درباره ایرلاین های آمریکا به همراه برچسب‌های احساسات مثبت و منفی است. (۱۲ نمره)

توجه :

- تمرینات عملی و برنامه نویسی به فرمت py. یا ipynb. همراه با پاسخنامه تمرین ارسال گردد.
- برای مطرح کردن سوالات در رابطه با تمرین‌ها، اولویت با سایت Quera می باشد اما در صورت نیاز، ارتباط از طریق ایمیل یا پیام رسانها نیز ممکن است.
- مضافاً اینکه در صورت کشف تقلب در هنگام تصحیح، نمره منفی لحاظ خواهد شد و همچنین استفاده به طور Copy-Paste از چت بات های هوش مصنوعی نیز نمره کسر خواهد گردید.

همیشه در پناه خدا موفق باشید

تیم دستیاران درس پردازش زبان طبیعی

امین رضانژاد (Head TA) و مرتضی ملائی (TA)