- **تمرینات تئوری (35 نمره)**

1. در اسناد مربوط به آثار شکسپیر تعداد رخداد Mercy را بجز Cleopatra و Antony مشخص کنید.

	Antony and Cleopatra	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth
Antony	1	1	0	0	0	1
Brutus	1	1	0	1	0	0
Caesar	1	1	0	1	1	1
Calpurnia	0	1	0	0	0	0
Cleopatra	1	0	0	0	0	0
mercy	1	0	1	1	1	1
worser	1	0	1	1	1	0

2. در یک سیستم Ranked Retrieval که هدف آن رتبه‌بندی اسناد بر اساس انطباق معنایی با کوئری‌ها است، برای رتبه‌بندی اسنادی که هم از نظر اطلاعات مرتبط و هم از نظر انطباق معنایی با کوئری‌های طولانی و کوتاه تفاوت دارند، چه رویکردهایی را می‌توان به کار برد؟(سه مورد را نام ببرید) در این سیستم، معیارهای زیر باید رعایت شوند:
اسنادی که اطلاعات بیشتری دارند، باید در رتبه‌های بالاتر قرار گیرند.
کوئری‌ها باید به صورت متن آزاد (free text) و نزدیک به زبان طبیعی باشند.

3. محاسبات مربوط به TF-IDF را برای کلمه "**زبان**" در اسناد زیر انجام دهید. سپس با استفاده از مقادیر به‌دست‌آمده از TF-IDF، تشابه کسینوسی بین جملات ۱ و ۲، ۱و ۳ ، ۲ و ۳ را محاسبه کنید.

سند۱:
آینده‌ی هوش مصنوعی در توانایی آن برای درک زبان انسان نهفته است، زیرا زبان کلید اندیشه و تعامل است.
سند۲ :
مدل‌های یادگیری عمیق تنها یک زمان معنا پیدا می‌کنند که به شیوه‌ای اخلاقی و شفاف استفاده شوند.
سند۳:
وقتی زبان را به مدل یاد می‌دهیم، در واقع داریم تفکر را مدل‌سازی می‌کنیم.

4. با توجه به جدول داده شده کدام دو سند شباهت بیشتری به هم دارند؟ شباهت cosine اسناد را دو به دو محاسبه کنید.(اعداد تعداد تکرار کلمات در هر سند میباشند)

Term	Doc 1	Doc 2	Doc 3
سبز	100	67	20
باران	10	0	11
نسیم	4	12	6

5. Hallucination در مدل های زبانی بزرگ چیست و تفاوت Hallucination با خطاهای معمول مدل‌های زبانی را توضیح دهید. از روش های متفاوت و مبتنی بر معماری داده، برای کاهش توهم در مدل‌ها مثال بزنید و توضیح دهید.

6. روش‌های Zero-shot ، Few-shot و Prompt Engineering سه رویکرد مهم در استفاده از مدل‌های زبانی بزرگ هستند.

الف) تفاوت‌های Zero shot، Few shot با Prompt Engineeringرا از نظر یادگیری، وابستگی به داده، و سطح دستکاری مدل شرح دهید.

ب) برای هر روش، یک کاربرد دنیای واقعی (real-world application) معرفی کرده و توضیح دهید چرا آن روش برای آن کاربرد مناسب‌تر است.

ج) فرض کنید بخواهید یک مدل LLM را برای سیستم پرسش‌پاسخ در یک دامنه‌ی تخصصی پزشکی مستقر کنید. کدام‌یک از این روش‌ها را انتخاب می‌کنید و چرا؟

7. معماری‌های Encoder-only، Decoder-onlyو Encoder-Decoder از پایه‌های Transformers هستند.

الف) سه نمونه از مدل‌های مشهور مبتنی بر هر یک از این معماری‌ها را نام ببرید و به‌طور خلاصه کاربرد رایج هر معماری را توضیح دهید.

ب) با توجه به نمودارهای رشد و روند استفاده‌ی رو به افزایش از معماری‌های Decoder-only در توسعه‌ی مدل‌های زبانی بزرگ ، تحقیق کنید چرا این معماری در ابعاد مقیاس‌پذیری و کارایی در فاز آموزش و راحتی در استنتاج ، نسبت به معماری‌های Encoder-only و Encoder-Decoder ترجیح داده می‌شود.

ج) در چه مسائلی معماری‌های Encoder-only یا Encoder-Decoder همچنان مزیت دارند.

8. مدل BERT با استفاده از روش یادگیری خودنظارتی (Self-supervised Learning) آموزش داده شده است. توضیح دهید منظور از یادگیری خودنظارتی چیست و چرا فرآیند آموزش BERT در این دسته قرار می‌گیرد.

- **سوالات چهارگزینه ای (بیان شرح علت انتخاب گزینه لازم است) (15 نمره)**

9. کدام‌یک از گزینه‌های زیر ویژگی مشترک مدل‌های زبانی بزرگ (LLM) مانند GPT و BERT است؟
   a. استفاده از RNN به‌عنوان لایه پایه
   b. استفاده از معماری ترنسفورمر
   c. آموزش تنها روی داده‌های برچسب‌دار
   d. توانایی تولید تصویر از متن

10. هدف اصلی از مرحله‌ی پیش‌آموزش (pretraining) در مدل‌های LLM چیست؟
   a. کاهش اندازه پارامترها
   b. تطبیق مدل با یک دامنه خاص
   c. یادگیری بازنمایی زبانی عمومی از داده‌های بزرگ
   d. افزایش سرعت inference

11. تفاوت اصلی بین مدل‌های autoregressive مانند GPT و مدل‌های autoencoding مانند BERT چیست؟
   a. تعداد لایه‌ها
   b. نحوه پردازش دنباله‌های متنی
   c. حجم داده‌ی مورد نیاز
   d. نوع داده‌های برچسب‌دار

12. کدام‌یک از موارد زیر، احتمالاً باعث افزایش hallucinationدر یک LLM می‌شود؟
   a. استفاده از داده‌های معتبر و متنوع
   b. آموزش مدل روی دامنه‌های محدود
   c. افزایش تعداد پارامترها
   d. کاهش طول prompt در زمان inference

13. فرض کنید یک LLM در زمان پاسخ‌دهی به سؤالات تخصصی دچار افت دقت می‌شود. کدام رویکرد زیر به‌صورت مؤثرتر به بهبود عملکرد کمک می‌کند؟
   a. افزایش سایز مدل و داده بدون تغییر معماری
   b. نیاز به داد استفاده از fine-tuning با داده‌های عمومی
   c. استفاده از retrieval-augmented generation (RAG) با داده‌های تخصصی
   d. کاهش نرخ یادگیری در مرحله inference

- **تمرینات عملی (50 نمره)**

1- فاین تیون کردن مدل (bert-base-uncased) برای دسته‌بندی متون به یکی از چهار کلاس 0: "World"و 1: "Sports"و 2: "Business"و 3: "Science/Technology" با استفاده از دیتاست "ag_news". در نهایت، مدل با استفاده از متریک‌های F1-Score و Accuracy ارزیابی خواهد شد. مراحل انجام این بخش به شرح زیر است:

الف) لود کردن ، اسپلیت کردن و در صورت نیاز پیش‌پردازش دیتاست.

بررسی توزیع برچسب‌ها در دیتاست و تعداد نمونه‌های موجود برای هر لیبل.(هدف از بررسی توزیع تعداد نمونه‌ها در هر کلاس، بررسی توازن دیتاست یا (Dataset Balancing است.)

در صورت نیاز، پیش‌پردازش داده‌ها (حذف نویز، stemming و...).

ب) لود کردن مدل، توکنایزر و توکنایز کردن دیتاست.

دیتاست را با استفاده از توکنایزر مدل به فرمت مناسب برای آموزش (با توجه به محدودیت طول توکن‌ها) تبدیل کنید.

ج) آموزش مدل

تنظیمات مناسب برای آموزش مدل (مانند تعداد اپوک‌ها، سایز بچ‌ها، و تنظیمات ارزیابی) را تعیین کنید.

د) ارزیابی مدل

مدل آموزش‌داده‌شده را با استفاده از تست ست ارزیابی کنید و متریک‌های Accuracy و F1-Score را محاسبه کرده و نتایج را گزارش دهید.

(Answer Retrieval Based on TF-IDF)

2- با استفاده از ابزار TfidfVectorizer، بردارهای ویژگی TF-IDF را از دیتاست " PQUAD " استخراج کرده و دیکشنری واژگان (vocabulary) آن را بسازید. سپس، یک(query) را به انتخاب خودتان ، با استفاده از دیکشنری واژگان لرن شده به بردار ویژگی تبدیل کنید. حالا با cosine_similarity شباهت کوئری را با هر **سوال** از دیتاست چک کنید و شباهت با بیشترین score را خروجی بگیرید. در نهایت، پاسخ مربوط به سوالی که بیشترین شباهت را با کوئری دارد، به‌عنوان پاسخ نهایی نمایش داده شود. (فقط از ستون ["question"] داده های train این دیتاست برای تشکیل بردار ویژگی استفاده کنید.)

سوال امتیازی (15 نمره)

3- از طریق روشهای Zero-Shot و Few-Shot مدل Llama-3 را برای پرسش و پاسخ استفاده کنید نتایج را بر اساس معیارهای F1-Score و Exact Match (EM) تحلیل و مقایسه کنید. در نهایت شرح دهید چه تعدا شات و به چه دلیل برای آماده سازی مدل انتخاب کردید. (محدودیتی در انتخاب مدل وجود ندارد و میتوانید از مدل های کوآنتایز شده هم استفاده کنید.)

از نمونه های زیر برای ارزیابی مدل خود استفاده کنید:

```
test_data = [
    {"question": "پایتخت ایران کجاست؟", "answer": "تهران پایتخت ایران است."},
    {"question": "چه کسی قانون جاذبه را کشف کرد؟", "answer": "آیزاک نیوتن قانون جاذبه را کشف کرد."},
    {"question": "پایتخت ایتالیا کدام شهر است؟", "answer": "رم پایتخت ایتالیا است."},
    {"question": "دریاچه بایکال در کدام کشور قرار دارد؟", "answer": "دریاچه بایکال در روسیه قرار دارد."},
    {"question": "سریع‌ترین حیوان خشکی چیست؟", "answer": "یوزپلنگ سریع‌ترین حیوان خشکی است."},
    {"question": "کدام سیاره به نام سیاره سرخ شناخته می‌شود؟", "answer": "مریخ به عنوان سیاره سرخ شناخته می‌شود."},
    {"question": "چند قاره در جهان وجود دارد؟", "answer": "هفت قاره در جهان وجود دارد."}
]
```

توجه :

- تمرینات عملی و برنامه نویسی به فرمت py. یا ipynb. همراه با گزارش، به انضمام پاسخنامه تمرین ارسال گردد.
- برای مطرح کردن سوالات در رابطه با تمرین‌ها، اولویت با سایت Quera می باشد اما در صورت نیاز، ارتباط از طریق ایمیل یا پیام رسانها نیز ممکن است.
- مضافاً اینکه در صورت کشف تقلب در هنگام تصحیح، نمره منفی لحاظ خواهد شد و همچنین استفاده به طور Copy-Paste از چت بات های هوش مصنوعی نیز نمره کسر خواهد گردید.

در پناه خدا موفق باشید

تیم دستیاران درس پردازش زبان طبیعی

امین رضانژاد (Head TA) و سید سعید رضوی (TA)